

La fouille de données ou "data mining" est un processus qui consiste à explorer de grandes quantités de données pour y découvrir des **informations utiles et inconnues au préalable**.

La fouille de données est un outil puissant pour transformer des données brutes en connaissances exploitables.

Ce TP porte sur l'exploration et la manipulation de données à l'aide de Python et de la bibliothèque Scikit-learn (SkLearn), le tout dans l'environnement Jupyter Notebook d'Anaconda. Vous allez apprendre à :

1. Installer et configurer l'environnement Anaconda (Jupyter) avec le package SkLearn.

2. Manipuler et explorer un fichier d'apprentissage :

- Ouvrir différents types de fichiers de données (benchmarks).
- Lire et afficher les données à l'aide de Pandas.
- Obtenir des informations de base sur les données :
 - Nombre d'instances (lignes).
 - Nombre et noms des attributs (colonnes).
 - Type de chaque attribut.
- Calculer et afficher les 5 nombres clés pour chaque attribut :
 - Minimum.
 - Maximum.
 - Médiane.
 - Premier quartile (Q1).
 - Troisième quartile (Q3).
- Visualiser la distribution des données :
 - Tracer les boxplots (boîtes à moustaches) de chaque attribut sur le même graphique.
 - Afficher le Scatter plot (nuage de points) du benchmark pour visualiser les relations entre les attributs.
- Calculer et afficher les statistiques descriptives :
 - Mode.
 - Moyenne.

- Médiane.
- Gérer les valeurs manquantes :
 - Identifier les valeurs manquantes.
 - Remplacer les valeurs manquantes par une méthode appropriée (par exemple, la moyenne).
- Normaliser les données :
 - Normalisation Min-Max.
 - Normalisation Z-score (standardisation).

Rapport à remettre le 27/10/2025